

Déterminants et Prédiction de la Mortalité Infantile au Cameroun

FONO BINDJEME Yannick Greg

Institut Saint Jean Ingenieur, Yaoundé

yannick.fono@saintjeaningenieur.org

INTRODUCTION : Le Cameroun enregistre des disparités persistantes de survie infantile selon les strates socioéconomiques et géographiques, dans un contexte où l'Afrique subsaharienne concentre la majorité des décès d'enfants dans le monde. Les outils de dépistage fondés sur les données restent insuffisamment développés à l'échelle nationale. Cette étude visait à caractériser le profil sociodémographique de la mortalité infantile au Cameroun et à construire un cadre de machine learning interprétable pour la prédiction du risque individuel.

MÉTHODES : Les données proviennent de l'Enquête Démographique et de Santé du Cameroun 2018 (fichier CMIR71FL), incluant 14 677 femmes âgées de 15 à 49 ans. Des analyses descriptives et bivariées (tests du khi-deux, t-tests) ont permis de caractériser l'échantillon et de sélectionner les variables prédictives. Six classificateurs supervisés ont ensuite été entraînés et comparés : Régression Logistique, Random Forest, Gradient Boosting, XGBoost, LightGBM et CatBoost ; sur un découpage stratifié 75/25 avec validation croisée 5-fold. Le déséquilibre des classes (ratio 3,98 :1) a été corrigé par pondération équilibrée. Des courbes d'apprentissage ont évalué le compromis biais-variance, et les valeurs SHAP ont assuré l'interprétabilité des modèles.

RÉSULTATS : La prévalence de la mortalité infantile était de 20,1 % dans l'ensemble de l'échantillon et de 28,1 % parmi les mères. Les analyses bivariées ont identifié 14 variables significativement associées ($p < 0,001$), notamment le niveau d'éducation, la parité et l'âge à la première naissance. Parmi les six modèles, XGBoost a obtenu les meilleures performances sur l'ensemble de test (AUC = 0,889 ; F1 = 0,643 ; Rappel = 0,720), suivi de LightGBM (AUC = 0,889) et CatBoost (AUC = 0,887). Les courbes d'apprentissage ont confirmé une bonne généralisabilité, sans surapprentissage. L'analyse SHAP a classé le nombre d'enfants nés vivants, l'âge maternel, le niveau d'éducation, l'âge à la première naissance et la taille du ménage comme prédicteurs les plus influents. Le pipeline complet a été déployé sous forme d'application web Streamlit pour l'estimation du risque en temps réel.

CONCLUSION : XGBoost, associé aux valeurs SHAP, constitue un cadre robuste et déployable pour la stratification populationnelle du risque de mortalité infantile au Cameroun. La cohérence entre les résultats des modèles et les tendances descriptives renforce la validité des facteurs identifiés. La scolarisation des filles, le retard de la première grossesse et le renforcement de l'accès aux soins maternels dans les zones rurales et défavorisées représentent les interventions prioritaires recommandées.

Mots clés : Mortalité infantile ; Cameroun ; Apprentissage automatique ; XGBoost ; SHAP ; Déterminants sociodémographiques.