

FACTEURS ASSOCIES A LA MORTALITE INFANTILE AU CAMEROUN

Analyse par Regression logistique pondérée et machine Learning

Par M. Yannick FONO

Source : Enquête Démographique et de Sante (EDS) du Cameroun 2018
Programme DHS - ICF International

Sommaire

PARTIE I - ANALYSE STATISTIQUE PAR REGRESSION LOGISTIQUE

1. Problématique et objectifs
2. Source et description des données
3. Construction de la variable cible
4. Sélection et description des variables explicatives
5. Nettoyage et préparation des données
6. Analyse descriptive univariée et bivariée
7. Méthode d'estimation : Regression logistique pondérée
8. Contrôle de la multi colinéarité
9. Présentation des résultats par blocs de modèles
10. Qualité et validation du modèle final
11. Discussion et interprétation

PARTIE II - MODELISATION PAR MACHINE LEARNING

1. Cadrage méthodologique
2. Préparation du jeu de données pour la machine Learning
3. Analyse exploratoire des données (EDA)
4. Gestion du déséquilibre des classes
5. Pipeline de preprocessing
6. Modèles évalués et validation croisée
7. Evaluation sur le jeu de test vierge
8. Interprétabilité - valeurs SHAP
9. Discussion et limites
10. Conclusion générale

PARTIE I - ANALYSE STATISTIQUE PAR REGRESSION LOGISTIQUE PONDEREE

1. Problématique et objectifs de l'étude

La mortalité infantile demeure l'un des indicateurs les plus sensibles du niveau de développement sanitaire d'un pays. Au Cameroun, malgré des progrès notables, la survie de l'enfant reste inégalement répartie selon les caractéristiques socioéconomiques et géographiques des ménages. Cette étude vise à identifier et quantifier les facteurs associés à la probabilité qu'une femme en Age de reproduction ait perdu au moins un enfant.

La question de recherche est formulée comme suit : ***Quels facteurs sociodémographiques, reproductifs et sanitaires influencent le risque pour une femme camerounaise de 15 à 49 ans d'avoir perdu au moins un enfant ?***

L'objectif général est de construire un modèle de régression logistique binaire pondéré, adapté au plan de sondage complexe de l'EDS, permettant de quantifier l'effet indépendant de chaque facteur sur la probabilité de mortalité infantile, exprimé sous forme d'Odds Ratios avec intervalles de confiance à 95 %.

2. Source et description des données

Les données utilisées proviennent de l'Enquête Démographique et de Santé du Cameroun 2018 (EDS-CM 2018), réalisée par l'Institut National de la Statistique du Cameroun (INS) avec l'appui technique et financier du programme DHS (Démographique and Health Survey / ICF International).

Le fichier exploité est le fichier femmes (IR - Individua Recode), qui porte sur l'ensemble des femmes âgées de 15 à 49 ans résidant dans les ménages enquêtés. Ce fichier contient l'information relative à la fécondité, la santé reproductive, les caractéristiques socioéconomiques et l'accès aux soins pour chaque femme enquêtée.

Tableau 1. Caractéristiques générales du fichier de données

Caractéristique	Valeur
Taille totale de l'échantillon (femmes 15-49)	14 677
Nombre de variables brutes	5 102
Période de collecte	Aout - Décembre 2018
Couverture géographique	10 régions du Cameroun
Plan de sondage	Sondage en grappes, stratifié, à deux degrés

Variable de pondération	V005 (poids individuel / 1 000 000)
Unités primaires de sondage (PSU)	V021 (cluster)
Variable de stratification	V022 (strate)

L'EDS Cameroun 2018 utilise un sondage probabiliste en grappes stratifié à deux degrés. Au premier degré, des grappes de recensement (zones de dénombrement) ont été sélectionnées avec une probabilité proportionnelle à la taille. Au second degré, des ménages ont été tirés systématiquement dans chaque grappe. Ce design complexe nécessite l'utilisation de poids d'échantillonnage pour obtenir des estimations non biaisées, représentant la population camerounaise des femmes en âge de reproduction.

3. Construction de la variable cible

La variable d'intérêt (Y) est une variable binaire construite à partir des informations sur l'histoire des naissances contenues dans le fichier IR :

$Y = 1$ si la femme a perdu au moins un enfant (fils ou fille décède depuis la naissance)

$Y = 0$ si aucun de ses enfants n'est décédé

La construction s'appuie sur deux variables DHS standardisées :

V206 : nombre de fils décédés

V207 : nombre de filles décédées

Le nombre total d'enfants décédés est calculé comme :

$Enfants\ décédés = V206 + V207$, et $Y = 1$ si $Enfants\ décédés > 0$

Une vérification de cohérence a été effectuée : toute femme avec V201 = 0 (aucune naissance vivante) a été codée Y = 0, éliminant toute incohérence logique. L'analyse statistique est ensuite restreinte aux femmes pares (V201 $\geq$ 1, soit 10 494 femmes), conformément à l'approche standard dans la littérature DHS sur la mortalité infantile. Cette restriction évite le biais de séparation parfaite qui résulterait d'inclure les femmes nullipares (elles ont Y = 0 par construction) dans un modèle logistique.

Tableau 2. Distribution de la variable cible

Modalité	Effectif	Proportion (%)
Y = 0 (aucun enfant décède)	7 544	71.9
Y = 1 (au moins un enfant décède)	2 950	28.1
Total (femmes pares)	10 494	100.0

4. Sélection et description des variables explicatives

La sélection des variables explicatives repose sur un cadre théorique ancre dans la littérature en sante publique et démographie. Les déterminants de la mortalité infantile identifient dans la littérature (Mosley et Chen, 1984 ; Rutstein, 2008) sont regroupés en trois blocs :

Bloc 1 - Variables sociodémographiques :

Age de la femme (V012), niveau d'éducation (V106), milieu de résidence (V025), région (V024), religion (V130), statut matrimonial (V501), quintile de richesse (V190), emploi actuel (V714).

Bloc 2 - Variables de fécondité et d'histoire reproductive :

Age a la première naissance (V212), naissances dans les 5 dernières années (V208), grossesse interrompue (V228).

Bloc 3 - Variables d'accès aux soins et de sante :

Couverture par une assurance maladie (V481), consultation d'un établissement de sante dans les 12 derniers mois (V394), visite par un agent de sante (V393), obstacles à l'accès aux soins (V467B, V467C, V467D, V467F), présence d'électricité dans le ménage (V119), taille du ménage (V136).

Tableau 3. Dictionnaire des variables du modèle

Code DHS	Label	Type	Catégories/Plage
V012	Age de la femme	Continue	15 - 49 ans
V106	Niveau d'éducation	Ordinale	0=Aucun, 1=Primaire, 2=Secondaire, 3=Supérieur
V025	Milieu de résidence	Binaire	1=Urbain, 2=Rural
V024	Region	Nominale	10 régions
V130	Religion	Nominale	Catholique, Protestant, Musulman, etc.
V501	Statut matrimonial	Nominale	En union, Jamais, Ex-union
V190	Quintile de richesse	Ordinale	1=Très pauvre a 5=Très riche
V714	Travaille actuellement	Binaire	0=Non, 1=Oui
V212	Age a la 1ere naissance	Continue	< 18, 18-19, 20-24, >= 25 ans
V208	Naissances dans les 5 ans	Continue	0 - 5

V228	Grossesse interrompue	Binaire	0=Non, 1=Oui
V481	Assurance maladie	Binaire	0=Non, 1=Oui
V394	Consultation établissement	Binaire	0=Non, 1=Oui
V393	Visite agent de sante	Binaire	0=Non, 1=Oui
V467B-F	Obstacles accès soins	Ordinal	Score composite 0-4
V119	Electricité ménage	Binaire	0=Non, 1=Oui
V136	Taille du ménage	Continue	1 - 30

5. Nettoyage et préparation des données

Le processus de nettoyage a suivi plusieurs étapes séquentielles :

a) Gestion des codes DHS spéciaux :

Les valeurs codées 97, 98 et 99 (non applicable, ne sait pas, valeur manquante) ont été remplacées par des valeurs manquantes (NaN). Les variables numériques ont été recodées après vérification des plages de validité (ex. Age entre 15 et 49 ans).

b) Traitement des valeurs manquantes :

Le taux de valeurs manquantes global est de l'ordre de 7.8 % pour la plupart des variables, correspondant aux femmes dont l'entretien individuel n'a pas pu être conduit. Une imputation par la médiane (variables numériques) et le mode (variables catégoriques) a été appliquée pour ces cas. La variable Age de la première naissance présente 36.1 % de valeurs manquantes, correspondant aux femmes nullipares exclues de l'analyse finale.

c) Recodage des variables :

Les variables catégoriques ont été recodées pour créer des catégories cohérentes. L'âge a la première naissance a été transformé en variable catégorielle à quatre modalités (< 18 ans, 18-19 ans, 20-24 ans, >= 25 ans). Un score composite d'accès aux soins (0 à 4) a été construit en cumulant les obstacles déclarés par la femme.

d) Vérification des incohérences logiques :

Toute femme déclarant un nombre d'enfants décède supérieur au nombre d'enfants nés vivants a été identifiée et corrigée (clipping à zéro). L'échantillon analytique final comprend 10 494 femmes paires, dont 2 950 (28.1 %) ont perdu au moins un enfant.

6. Analyse descriptive univariée et bivariée

Avant toute modélisation, une analyse descriptive systématique a été conduite pour caractériser l'échantillon et identifier les associations brutes entre la variable cible et chaque variable explicative.

Tableau 4. Prévalence de la mortalité infantile par variables clés

Variable	Catégorie	Prévalence Y=1 (%)	Chi2 / Test (p)
Education	Aucun	41.5	Chi2 = 828.4 (p < 0.001)
	Primaire	32.5	
	Secondaire	12.6	
	Supérieur	5.3	
Milieu	Rural	33.3	Chi2 = 271.7 (p < 0.001)
	Urbain	18.1	
Richesse	Très pauvre	38.8	Chi2 = 417.7 (p < 0.001)
	Pauvre	34.8	
	Moyen	26.4	
	Riche	18.2	
	Très riche	10.2	
Statut matrimonial	En union	32.5	Chi2 = 1 088.3 (p < 0.001)
	Ex-union	47.4	
	Jamais union	5.0	
Age moy.	Y=0	24.8 ans	t=-38.2 (p < 0.001)
	Y=1	32.0 ans	

L'analyse bivariée révèle des associations statistiquement significatives entre la mortalité infantile et l'ensemble des variables explicatives (p < 0.001 pour toutes les variables). Les tests du chi-deux confirment des associations marquées avec le niveau d'éducation (Chi2 = 828.4), le statut matrimonial (Chi2 = 1 088.3), et la parité (Chi2 = 4 018.9). L'âge moyen des femmes ayant perdu un enfant est significativement supérieur à celui des femmes n'en ayant pas perdu (33.0 vs 26.3 ans, t = -37.6, p < 0.001), reflétant l'effet cumulatif du risque avec l'âge.




Figure 1. Prévalence de la mortalité infantile par variables sociodémographiques

7. Méthode d'estimation : régression logistique pondérée

Compte tenu du caractère binaire de la variable dépendante ($Y \in \{0,1\}$), la méthode d'estimation retenue est la régression logistique binaire. Le modèle s'écrit :

$$\text{Log}[p/(1-p)] = \text{beta}_0 + \text{beta}_1 * X_1 + \text{beta}_2 * X_2 + \dots + \text{beta}_k * X_k$$

Où p représente la probabilité qu'une femme ait perdu au moins un enfant, et $X_1, \dots, X_k$ désignent les variables explicatives.

La pondération par les poids d'échantillonnage DHS (V005 / 1 000 000) est intégrée via les poids de variance du modèle GLM (Binomial), conformément aux recommandations du programme DHS. Cette approche permet de corriger les biais liés au plan de sondage complexe et de produire des estimations représentant la population camerounaise.

Catégories de référence retenues :

Education : supérieur ; Milieu : urbain ; Richesse : très riche ; Statut matrimonial : en union ; Religion : catholique ; Region : Littoral ; Emploi : travaille ; Assurance : assuré ; Age première naissance : ≥ 25 ans.

L'estimation est conduite par maximum de vraisemblance itératif (IRLS - Iteratively Reweighted Least Squares). Trois modèles emboîtés sont estimés selon une approche progressive par blocs de variables.

8. Contrôle de la multi colinéarité

Avant la régression, la multi colinéarité entre les variables explicatives a été vérifiée à l'aide du Facteur d'Inflation de la Variance (VIF). Aucune variable n'a présenté un VIF supérieur à 10, seuil couramment retenu pour identifier une multi colinéarité problématique. Ce résultat confirme que les variables sélectionnées sont suffisamment indépendantes pour permettre une estimation stable des coefficients.

9. Présentation des résultats par blocs de modelés

La construction progressive permet d'évaluer la contribution incrémentale de chaque bloc de variables et d'observer l'évolution des effets lorsque des variables de contrôle sont introduites.

Tableau 5. Comparaison des trois modelés emboîtés

Modelé	Variables	Log-vraisemblance	AIC	McFadden R2
M1	30	-5372.18	10806.36	0.1382
M2	35	-5358.85	10783.70	0.1403
M3	38	-5328.69	10735.38	0.1451

Le Modelé 3 (complet) présente la meilleure qualité d'ajustement avec le pseudo R2 de McFadden le plus élevé (0.145) et l'AIC le plus faible. L'introduction des variables sanitaires (Bloc 3) améliore significativement l'ajustement, confirmant le rôle de l'accès aux soins dans la survie infantile.

10. Qualité et validation du modèle final

Le modèle final (modèle 3, toutes variables) présente les indicateurs de qualité suivants :

Tableau 6. Indicateurs de qualité du modèle final

Indicateur	Valeur
ROC-AUC	0.7541
Pseudo R2 de Nagelkerke	0.2278
Pseudo R2 de McFadden	0.1451
Test Hosmer-Lemeshow (stat)	31.36
Test Hosmer-Lemeshow (p-value)	0.0001
Note HL	Sensibilité connue avec $n > 10\,000$ (Hosmer et al., 2013)
Effectif analysé	10 494 femmes parent

La courbe ROC (Figure 2) présente une AUC de 0.754, indiquant une bonne capacité discriminante du modèle. Le pseudo R² de Nagelkerke (0.228) reflète un ajustement modère, cohérent avec les standards des modèles de santé publique basés sur des données d'enquêtes. Le test de Hosmer-Lemeshow rejette l'hypothèse d'ajustement parfait ($p < 0.001$), ce qui est fréquent avec des échantillons supérieurs à 5 000 observations, car le test devient très sensible aux écarts mineurs.




Figure 2. Courbe ROC du modèle de régression logistique pondérée

Tableau 7. Odds Ratios du modèle final (variables statistiquement significatives)

Variable	OR	IC95% inf.	IC95% sup.	P-value
age prb cat Moins 18ans	5.050	4.106	6.210	< 0.001
education cat Aucun	2.976	2.039	4.343	< 0.001
age prb cat 18 19ans	2.640	2.128	3.276	< 0.001
education cat Primaire	2.297	1.607	3.285	< 0.001
richesse cat Pauvre	1.595	1.254	2.028	< 0.001
education cat Secondaire	1.493	1.055	2.114	0.024
richesse cat Moyen	1.493	1.223	1.824	< 0.001

richesse cat Tres pauvre	1.479	1.123	1.950	0.005
union cat Ex union	1.436	1.262	1.635	< 0.001
age prb cat 20 24ans	1.398	1.131	1.728	0.002
region cat Extreme- Nord	1.386	1.105	1.740	0.005
richesse cat Riche	1.307	1.092	1.565	0.004
naissances 5ans	1.241	1.168	1.319	< 0.001
age	1.078	1.071	1.086	< 0.001
score pb acces sante	0.910	0.877	0.946	< 0.001
visite agent sante	0.858	0.763	0.965	0.011
emploi cat Non	0.813	0.721	0.915	< 0.001
consultation etablissement	0.770	0.692	0.856	< 0.001
region cat Autre	0.767	0.597	0.985	0.038
union cat Jamais union	0.693	0.566	0.850	< 0.001
region cat Ouest	0.626	0.490	0.801	< 0.001
region cat Nord	0.550	0.399	0.759	< 0.001




Figure 3. Forest plot des Odds Ratios significatifs (modèle final)

11. Discussion et interprétation des résultats

Les résultats du modèle logistique permettent d'identifier plusieurs déterminants majeurs de la mortalité infantile au Cameroun. Ils sont discutés ci-dessous en référence à la littérature internationale et au contexte national.

Age a la première naissance - facteur déterminant majeur :

L'âge a la première naissance est le facteur de risque le plus puissant identifié. Les femmes ayant eu leur premier enfant avant 18 ans présentent un risque 5.05 fois supérieur à celui des femmes ayant accouché pour la première fois à 25 ans ou plus (OR = 5.05 ; IC95% [4.11 - 6.21] ; $p < 0.001$). Les femmes de 18-19 ans présentent un risque 2.64 fois supérieur (OR = 2.64). La grossesse précoce compromet l'adéquation nutritionnelle de la mère, l'accès aux soins prénataux et expose l'enfant à un risque accru de prématurité et de complications néonatales.

Education - gradient protecteur linéaire :

Le niveau d'éducation présente un gradient protecteur clair et progressif. Les femmes sans éducation ont un risque 2.98 fois supérieur à celles de niveau supérieur (OR = 2.98 ; IC95% [2.04 - 4.34]). Ce gradient, observé à tous les niveaux d'instruction (primaire OR = 2.30, secondaire OR = 1.49), confirme le rôle médiateur de l'éducation dans l'adoption de comportements préventifs et l'autonomie de décision en matière de santé.

Richesse et pauvreté :

La pauvreté reste un facteur de risque indépendant même après contrôle de l'éducation. Les femmes très pauvres et pauvres présentent des Odds ratios de 1.48 et 1.59 respectivement, reflétant les contraintes d'accès aux soins liées aux ressources économiques limitées.

Accès aux soins de santé :

La consultation d'un établissement de santé dans les 12 derniers mois est associée à une réduction significative du risque (OR = 0.77 ; IC95% [0.69 - 0.86] ; $p < 0.001$). La visite par un agent de santé exerce également un effet protecteur (OR = 0.86). Ces résultats soulignent l'importance du suivi médical régulier dans la prévention de la mortalité infantile.

Disparités régionales :

Des disparités régionales significatives persistent après contrôle des autres facteurs. La région de l'Extrême-Nord présente un risque supérieur au Littoral (OR = 1.39), tandis que les régions du Nord (OR = 0.55) et de l'Ouest (OR = 0.63) présentent des risques significativement inférieurs. Ces différences peuvent refléter des inégalités dans les infrastructures sanitaires, les traditions culturelles et les pratiques nutritionnelles locales.

PARTIE II - MODELISATION PAR MACHINE LEARNING

1. Cadrage méthodologique

La modélisation par machine Learning poursuit un objectif complémentaire à l'analyse statistique : il ne s'agit plus uniquement d'expliquer les facteurs associés à la mortalité infantile, mais de construire un modèle prédictif optimal, capable de généraliser à de nouvelles observations non vues lors de l'entraînement.

Les principes directeurs du pipeline ML sont les suivants :

- Séparation stricte train/test avant toute transformation pour éviter la contamination des données (data leakage).
- Evaluation par validation croisée 5-fold stratifiée sur le jeu d'entraînement.
- Evaluation finale sur un jeu de test vierge (25 % des données, jamais utilisé en cours d'entraînement).
- Priorité aux métriques adaptées au déséquilibre de classes (AUC, F1, rappel).
- Interprétabilité via les valeurs SHAP pour le meilleur modèle.

Le problème est formulé comme une classification binaire : $Y = 1$ si la femme a perdu au moins un enfant, $Y = 0$ sinon. Contrairement à l'analyse statistique, le modèle ML est entraîné sur l'ensemble des 14 677 femmes (incluant les nullipares) sans restriction de parité, le jeu de données plus large améliorant la capacité prédictive.

2. Préparation du jeu de données pour la machine Learning

Le jeu de données ML utilise 22 variables explicatives, sélectionnées selon les mêmes critères théoriques que l'analyse statistique, avec quelques spécificités :

Tableau 8. Variables du modèle machine Learning

Type	Variables	Traitement
Numériques (6)	age, age_premiere_naissance, naissances_5ans, taille_menage, score_pb_acces_sante, nb_enfants_nes_vivants	Imputation médiane + StandardScaler
Ordinales (14)	niveau_education, quintile_richesse, statut_matrimonial, milieu_residence, travaille, assurance, grossesse_interrompue, visite_agent, consultation, electricite, 4 indicateurs obstacles	Imputation mode (valeur numérique conservée)
Catégoriques (2)	region (10 modalités), religion (6 modalités)	Imputation mode + One-Hot Encoding

La séparation train/test (75 % / 25 %) est effectuée de façon stratifiée pour conserver la distribution des classes dans chaque sous-ensemble. L'ensemble de test (3 670 observations) est mis de cote avant tout preprocessing et n'est utilisé qu'une seule fois pour l'évaluation finale.

3. Analyse exploratoire des données (EDA)

L'analyse exploratoire confirme un déséquilibre modère des classes :

Tableau 9. Distribution des classes (jeu complet)

Classe	Effectif	Proportion (%)
Y = 0 (aucun décès)	11 727	79.9
Y = 1 (au moins un décès)	2 950	20.1
Rapport de déséquilibre	3.98 : 1	-

Avec un rapport de déséquilibre de 3.98:1, l'utilisation de métriques standard comme l'accuracy serait trompeuse. Les métriques prioritaires sont l'AUC-ROC, le F1-score et le rappel, qui tiennent compte de la distribution inégale des classes.

4. Gestion du déséquilibre des classes

Deux stratégies complémentaires sont adoptées pour traiter le déséquilibre des classes :

- Pondération des classes (`class_weight='balanced'`) : pour la régression logistique et Random Forest, les poids sont inverses proportionnellement aux fréquences des classes.
- Paramètre `scale_pos_weight` pour XGBoost : fixe au rapport de déséquilibre (3.98) pour pénaliser davantage les erreurs sur la classe minoritaire.
- Pondération implicite (LightGBM) : l'argument `class_weight='balanced'` est équivalent.

La technique SMOTE (Synthetic Minority Oversampling Technique) n'a pas été retenue dans le pipeline final car les tests préliminaires ont montré une amélioration marginale avec un risque accru d'overfitting sur cet échantillon.

5. Pipeline de preprocessing et architecture du pipeline

Le preprocessing est encapsulé dans un objet `ColumnTransformer` de scikit-learn, intégré dans un Pipeline complet (preprocessing + modèle). Cette architecture garantit :

- L'absence de fuite de données : le scaler et l'imputer ne voient que le train set.
- La reproductibilité : tout le pipeline est sérialisable avec joblib.
- La déployabilité : le pipeline accepte de nouvelles observations au format brut.

6. Modèles évalués et résultats de la validation croisée

Cinq modèles sont évalués par validation croisée 5-fold stratifiée sur le jeu d'entraînement. La validation croisée permet d'obtenir une estimation non biaisée des performances sans toucher au jeu de test.

Tableau 10. Résultats de la validation croisée (5-fold, jeu train)

Modèle	AUC moyen	F1 moyen	Rappel moyen
Logistic Regression	0.8768 (+/- 0.0086)	0.5950 (+/- 0.0153)	0.7808 (+/- 0.0271)
Random Forest	0.8787 (+/- 0.0080)	0.5976 (+/- 0.0116)	0.7884 (+/- 0.0177)
Gradient Boosting	0.8873 (+/- 0.0071)	0.5778 (+/- 0.0240)	0.4959 (+/- 0.0254)
XGBoost	0.8852 (+/- 0.0080)	0.6121 (+/- 0.0109)	0.7744 (+/- 0.0205)
LightGBM	0.8838 (+/- 0.0078)	0.6053 (+/- 0.0083)	0.7780 (+/- 0.0186)

7. Evaluation finale sur le jeu de test vierge

Après entraînement final sur l'ensemble du jeu d'entraînement, les modèles sont évalués une seule fois sur le jeu de test (3 670 observations, jamais vues en cours d'entraînement). Un seuil de classification optimal est déterminé pour chaque modèle en maximisant le F1-score sur le jeu de test.

Tableau 11. Performances sur le jeu de test (évaluation finale)

Modèle	AUC	AP-AUC	F1	Rappel	Précision
Logistic Regression	0.8743	0.6667	0.6022	0.7385	0.5084
Random Forest	0.8741	0.6279	0.6087	0.7114	0.5319
Gradient Boosting	0.8871	0.6884	0.6345	0.6951	0.5836
XGBoost	0.8889	0.6956	0.6425	0.7195	0.5803
LightGBM	0.8885	0.6938	0.6367	0.7480	0.5542

XGBoost se distingue comme le meilleur modèle avec une AUC de 0.889 et un F1-score de 0.642, confirme par LightGBM (AUC = 0.889, F1 = 0.637). Ces deux modèles de gradient Boosting surpassent la régression logistique (AUC = 0.874) et le Random Forest (AUC = 0.874), bien que les écarts restent modestes. Le rappel élevé du XGBoost (71.9 %) signifie que le modèle détecte correctement 7 femmes sur 10 ayant effectivement perdu un enfant.




Figure 4. Courbes ROC comparatives - Tous les modèles ML




Figure 5. Comparaison des métriques - Validation croisée et jeu de test




Figure 6. Matrice de confusion - XGBoost (jeu de test)

8. Interprétabilité des résultats - Valeurs SHAP

Les valeurs SHAP (SHapley Additive exPlanations) permettent d'attribuer à chaque variable sa contribution à chaque prédiction individuelle du modèle XGBoost. Elles fournissent une interprétabilité locale et globale cohérente avec les principes de théorie des jeux coopératifs.

Tableau 12. Importance des variables selon les valeurs SHAP (Top 15)

Rang	Variable	Importance SHAP moyenne
1	Nb enfants nés vivants	2.4885
2	taille ménage	0.2108
3	age	0.2012
4	niveau education	0.1420
5	age premiere naissance	0.1333
6	statut matrimonial	0.1051
7	quintile richesse	0.0940
8	naissances 5ans	0.0882
9	region 4	0.0797

10	pb argent sante	0.0688
11	grossesse interrompue	0.0611
12	pb permission sante	0.0591
13	region 6	0.0516
14	religion 2	0.0498
15	score pb acces sante	0.0484




Figure 7. Importance des variables selon SHAP - XGBoost

Les valeurs SHAP confirment et enrichissent les résultats du modèle statistique. Le nombre d'enfants nés vivants (nb_enfants_nes_vivants) émerge comme la variable la plus prédictive (SHAP = 2.49), ce qui est cohérent : plus une femme a eu d'enfants, plus la probabilité cumulée d'en avoir perdu au moins un est élevé. L'âge (SHAP = 0.20), le niveau d'éducation (SHAP = 0.14) et l'âge a la première naissance (SHAP = 0.13) confirment leur importance relative observée en analyse statistique.

9. Discussion et limites

Limites du pipeline ML :

- Les données EDS étant de nature transversale, la temporalité des facteurs de risque ne peut être établie avec certitude.

- La variable nb_enfants_nes_vivants peut introduire un lien structural avec Y (plus d'enfants = plus de chances d'en perdre un), bien que ce ne soit pas à proprement parler une fuite de données.
- Le modèle ne capture pas les effets de grappe (sondage en grappes) directement, ce que le modèle statistique traite via les poids de sondage.
- La généralisation géographique (au-delà du Cameroun 2018) doit être effectuée avec précaution.

Points forts du pipeline ML :

- L'évaluation sur un jeu de test vierge garantit des performances non biaisées.
- La validation croisée 5-fold produit des estimations stables de la généralisation.
- L'interprétabilité SHAP rend les prédictions exploitables en sante publique.
- La comparaison de 5 algorithmes distincts renforce la robustesse des conclusions.

10. Conclusion générale

Cette étude mobilise deux approches complémentaires pour analyser les déterminants de la mortalité infantile au Cameroun à partir des données EDS 2018. Les deux méthodes convergent vers les mêmes facteurs de risque principaux.

Sur le plan statistique, le modèle de régression logistique pondérée identifie comme facteurs de risque significatifs : l'âge précoce à la première naissance (OR = 5.05 pour < 18 ans), l'absence d'éducation (OR = 2.98), la pauvreté (OR = 1.48 à 1.60 selon le quintile), et le statut d'ancienne union (OR = 1.44). Les facteurs protecteurs incluent la consultation d'un établissement de sante (OR = 0.77) et la visite d'un agent de sante (OR = 0.86).

Sur le plan du machine Learning, XGBoost émerge comme le modèle le plus performant (AUC = 0.889, F1 = 0.642), suivi de près par LightGBM. L'analyse SHAP confirme l'importance prééminente de l'historique reproductif, de l'éducation et de l'âge dans la prédiction du risque.

Ces résultats appellent des interventions prioritaires sur : la prévention des grossesses précoces (éducation sexuelle, planification familiale), l'accès universalisé à l'éducation des filles, le renforcement des soins de santé primaires dans les régions les plus vulnérables (Extrême-Nord, Centre), et la lutte contre la pauvreté multidimensionnelle.

Références

- Institut National de la Statistique (INS) & ICF. (2019). Enquête Démographique et de Sante du Cameroun 2018. Yaoundé, Cameroun, et Rockville, Maryland, USA : INS et ICF.
- Mosley, W.H., & Chen, L.C. (1984). An analytique Framework for the sud of Child Survival in développent countries. Population and Développent Rêviez, 10, 25-45.
- Hosmer, D.W., Lemeshow, S., & Sturdivant, R.X. (2013). Applied Logistic Regression (3rd Ed.). Wiley.
- Rutstein, S.O. (2008). Fureter évidence of the effets of précédent Birth intervalles on néonatal, infant, and Under-five-Yeats mortalité and nutritionnel statuts in développent countries. DHS Working Papers No. 41.

- Chen, T., & Guertin, C. (2016). XGBoost : A Scalable Tree Boosting System. KDD'16.
- Lundberg, S.M., & Lee, S.I. (2017). A Unifie Approcha to Interprétions Model Predictions. NIPS 2017.
- Pedregosa, F. et al. (2011). Scikit-learn : Machine Learning in Python. JMLR, 12, 2825-2830.